

Los asesores llaman al que llegó primero, no al que más probabilidad tiene de comprar

Lo que plantea el gerente comercial

- Más de **3.000 leads** al mes, en una sola bandeja
- Cierra **menos de 1 de cada 10** leads gestionados
- **4 de cada 10** no se tocan en las primeras 24 horas
- Lo que el cliente dice por WhatsApp (moto, inicial, crédito) **no llega al CRM**: el asesor arranca de cero
- Tres comercializadoras comparten el CRM y **ninguna puede ver clientes de otra**

Lo que dicen los datos

15,1 %

cierra un lead contactado en menos de 1 hora

5,8 %

cierra si el contacto tarda más de 48 horas

Histórico de 2.021 leads con desenlace. Tasa base: 9,75 %.


451

clientes llevan más de 48 h sin que nadie los contacte

823 de 1.451

clientes no tienen conversación: el score no puede depender solo de la IA

Un pipeline diario que deja a cada asesor su lista priorizada



Orquestación

- n8n dispara a las 6:00 un solo POST
- Sin lógica en n8n: el plan B es run-all por SSH

Datos

- Postgres 18, 10 migraciones versionadas
- Aislamiento por empresa con RLS en el motor

Producto

- API FastAPI + tablero Angular
- Caddy con HTTPS, en un VPS con Docker Compose

Datos sucios resueltos con reglas medibles, no a mano

59

fechas mm/dd que un default dd/mm habría leído mal en silencio

Cascada: formato inequívoco → ventana de fechas del propio dataset → coherencia con el contacto.

10 dígitos

teléfonos con +57, guiones, paréntesis y espacios

Un solo número irrecuperable (300123): queda marcado inválido y fuera del dedupe.

190 → 24

textos de modelo resueltos a SKUs del catálogo

0 sin resolver y 0 SKUs inventados: "Bajaj" a secas queda como marca, sin adivinar la línea.

3

filas plantadas al final de leads.csv

LD-01501 ("prueba prueba", día 33) y dos copias exactas: van a cuarentena, nada se borra.

49

personas fusionadas dentro de su empresa

28 escribieron por dos canales distintos. 1.500 leads quedan en 1.451 clientes.

91

teléfonos compartidos entre empresas: NO se fusionan

Fusionarlos rompería la separación por empresa. La identidad es (empresa, teléfono).

Extraer lo que dice el cliente, y medir cuánto acierta

Cómo funciona

- gpt-4o-mini con **JSON Schema estricto**: modelo, inicial, forma de pago, intención, objeción, cita y cotización
- Cada extracción guarda la **cita textual del cliente** que la sustenta: se audita en vivo
- Caché por hash: **640 leads en 3 min 23 s**; reejecutar no vuelve a pagar ni cambia resultados
- La salida del LLM **nunca se corrige en silencio**: las violaciones se registran

15 conversaciones etiquetadas a mano

88 %

acierto en todos los campos

93 %

en los campos que entran al score

Muestra elegida por dificultad, no aleatoria: mide los casos que más tensionan el schema.

Método: medir antes de iterar

- Ruido del modelo medido antes de atribuir mejoras al prompt
- 5 versiones del prompt; arreglos de causa, no advertencias
- Caso "tengo 0 millones": la muestra de 10 lo escondía. **30 % → 97 %** al corregir la definición de negocio


Un score explicable, validado contra el histórico

Puntos por señal (regresión logística, logit_v2)

Señal de la conversación	Sí	No	Sin información
Pidió cita	+24	-10	0
Manifestó cuota inicial	+16	-19	0
Forma de pago	contado +32	crédito -9	0

- Sin información = 0 puntos: no saber no se castiga como un "no"
- Urgencia = multiplicador, no variable: $\leq 1\text{ h} \times 1,55 \dots > 48\text{ h} \times 0,59$

Validación fuera de pliegue



El top 20 % del score cierra **1,31x** la tasa base (13 % contra 9,75 %)

Honesto: AUC 0,552, señal débil pero real. Solo variables que existen al priorizar (cuesta 3,1 puntos). Logística frente a Random Forest, Gradient Boosting y SVM con CV repetida: empate, se eligió la explicable.

Dos colas y capacidad real por punto de venta

El riesgo: un orden global por probabilidad deja al final a los clientes que nadie ha tocado, porque la urgencia castiga haber esperado. Es justo la queja del gerente.

451

Primer contacto

nadie del grupo los
ha contactado

860

Seguimiento

ya contactados,
siguen activos

140

Fuera de cola


estado consolidado:
descartado

Orden dentro de cada cola: primero el score; a igual score, el cliente más fresco.

Capacidad por punto de venta

- Un asesor solo atiende su punto de venta: **la capacidad no se suma global**
- Primer contacto recibe **[pendientes / 2 días]** y el resto va a seguimiento
- Lo que sobra en una cola pasa a la otra: **688 de 694 plazas** usadas
- La temperatura mide calidad, no capacidad: **12 clientes alta y 4 media no entran hoy** porque su punto de venta se llenó

El cuello de botella es la dotación, no la cantidad de leads



77-100

clientes activos por punto de venta

12-86

de capacidad diaria

Misma empresa (EMP-03), misma cartera

PV-013: 84 clientes, 7,0 días

PV-012: 80 clientes, 0,9 días (le sobran plazas)

- Los dos peores son los **únicos con un asesor inactivo**
- **Acción:** reasignar dotación dentro de EMP-03

Aislado, operando y con los límites declarados

Separación por empresa

- **empresa_id** sale del token firmado, nunca de un parámetro
- Postgres filtra con RLS (**FORCE + rol app_tenant**): un WHERE olvidado no filtra datos
- Verificado en producción: EMP-01 ve PV-001 a 005; EMP-03, PV-011 a 015

Operación

- n8n corrió solo a las 6:00
- Reinicio y apagado del servidor probados: **todo vuelve solo**
- Snapshot tomado, SSH solo con llave y plan B escrito
- **104 tests**, incluido el aislamiento contra datos reales

Con más tiempo

- **Interacción cita × crédito**: con crédito, pedir cita no mejora el cierre
- Revocar la sesión de un usuario desactivado
- Validar el LLM con una muestra aleatoria más grande
- Datos sintéticos: formulario y conversación resultaron independientes